UNIVERSIDADE PRESBITERIANA MACKENZIE

BRUNA DA SILVA AGUIAR
ISABELLA DE MORAES SILVA
BEATRIZ DE MACEDO SÁ TELES
LIVIA MARIANO DE AZEVEDO

DA TRANSAÇÃO AO INSIGHT: ESTRUTURAÇÃO DE DADOS DE UM E-COMMERCE

São Paulo

2026

BRUNA DA SILVA AGUIAR
ISABELLA DE MORAES SILVA
BEATRIZ DE MACEDO SÁ TELES
LIVIA MARIANO DE AZEVEDO

DA TRANSAÇÃO AO INSIGHT: ESTRUTURAÇÃO DE DADOS DE UM E-COMMERCE

Projeto Aplicado II – 3° Semestre

Github: https://github.com/isabelladmo/Projeto-Aplicado-II

ORIENTADOR: Profº. Felipe Albino dos Santos

São Paulo

2026

Sumário

1. PREMISSAS DO PROJETO 4
1.1 Organização escolhida....4
1.2 Área de atuação....4
2. APRESENTAÇÃO DOS DADOS....4
3. OBJETIVOS DO PROJETO....5
3.1 Objetivo geral....5
3.2 Objetivos específicos....5
4. METAS....6
5. QUESTÃO DO NEGÓCIO....7
6. RESULTADOS ESPERADOS....7
7. LINGUAGEM E BIBLIOTECAS....8
8. BASES TEÓRICAS DOS MÉTODOS....9
8.1 Análise RFM....9
8.2 Transformação dos dados....10
8.3 Padronização....10
8.4 Aprendizado não supervisionado e K-Means....10
8.5 Definição do número de clusters....11
8.6 Inertia e Método do Cotovelo....11
9. DEFINIÇÃO DA ACURÁCIA....12
10. ANÁLISE EXPLORATÓRIA....13
11. TRATAMENTO, PREPARAÇÃO E TREINAMENTO....14
12. RESULTADOS E ARQUIVOS GERADOS....19
12.1 rfm_clientes.csv....19
12.2 perfil_clusters.csv....20
12.3 avaliacao_clusters.csv....20
12. 4 clientes_com_clusters.csv....20
13. CRONOGRAMA....21

1. PREMISSAS DO PROJETO

1.1 Organização escolhida

Para o desenvolvimento do projeto será considerada uma empresa importadora e de comércio eletrônico (e-commerce) de artigos de decoração, presentes e utilidades domésticas.

A organização realiza operações comerciais com clientes de diferentes localidades e possui um grande volume de registros relacionados a produtos, clientes, faturas, quantidades comercializadas, preços e datas de compra.

Diante desse cenário, torna-se importante estruturar os dados de maneira adequada, permitindo não apenas seu armazenamento e gerenciamento, mas também a realização de análises capazes de identificar padrões de vendas e comportamento dos clientes.

1.2 Área de atuação

A empresa atua no segmento de varejo e atacado multicanal, com foco na comercialização de artigos de decoração, presentes e utilidades domésticas.

Por realizar transações com clientes de diferentes países, incluindo Reino Unido e França, a organização possui características de uma operação internacional, gerando dados que permitem analisar aspectos como distribuição geográfica das vendas, comportamento de compra dos clientes, desempenho dos produtos e faturamento.

2. APRESENTAÇÃO DOS DADOS

O projeto utilizará o conjunto de dados Online Retail, disponibilizado pelo UCI Machine Learning Repository.

A base apresenta transações realizadas por uma empresa de varejo eletrônico entre 01/12/2010 e 09/12/2011, contendo informações sobre produtos, clientes, faturas, quantidades, preços, datas das transações e países.

O conjunto original possui 541.909 registros e 8 variáveis:

- InvoiceNo - Número da fatura/transação

- StockCode - Código do produto
- Description - Descrição do produto
- Quantity - Quantidade de produtos adquiridos
- InvoiceDate - Data e horário da transação
- UnitPrice - Preço unitário do produto
- CustomerID - Identificação do cliente
- Country - País de residência do cliente

A base apresenta características adequadas para o desenvolvimento do projeto, pois permite trabalhar simultaneamente com modelagem de dados, consultas, análise exploratória e técnicas de aprendizado de máquina.

Inicialmente, os dados serão analisados para identificar valores ausentes, registros de cancelamento, valores negativos, possíveis inconsistências e outras características que possam interferir nas análises posteriores.

A partir dessa análise, será desenvolvida uma estrutura de banco de dados relacional que organize as informações de maneira mais eficiente, permitindo posteriormente a realização de consultas e análises sobre clientes, produtos e transações.

3. OBJETIVOS DO PROJETO

3.1 Objetivo geral

Estruturar e analisar os dados transacionais de uma empresa de varejo eletrônico por meio da construção de um banco de dados relacional e da aplicação de técnicas de análise de dados, buscando otimizar o controle de estoque, gerar um rastreio de faturamento por região e identificar padrões de vendas e comportamento dos clientes (CustomerID) que possam apoiar a tomada de decisões comerciais.

3.2 Objetivos específicos

Para alcançar o objetivo geral, o projeto terá como objetivos:

1. Analisar e compreender a estrutura da base de dados original;
2. Identificar as principais entidades, atributos e relacionamentos presentes nos dados;

3. Identificar redundâncias, inconsistências e possíveis problemas de qualidade na base original;
4. Aplicar técnicas de normalização para melhorar a organização e a integridade dos dados;
5. Modelar um banco de dados relacional composto por entidades como clientes, produtos, faturas e itens das faturas;
6. Estabelecer relacionamentos e chaves entre as tabelas, garantindo a integridade referencial;
7. Organizar os dados de forma que seja possível realizar consultas e análises relacionadas às vendas, clientes, produtos e regiões;
8. Desenvolver consultas e relatórios analíticos para extração de informações relevantes sobre as operações comerciais;
9. Documentar o processo de transformação da base original até a estrutura relacional proposta;
10. Disponibilizar a documentação, scripts e resultados do projeto em um repositório no GitHub.

4. METAS

A principal meta do projeto é transformar a base de dados transacional original em uma estrutura relacional organizada, normalizada e adequada para consultas, análises e geração de insights sobre as operações comerciais e o comportamento dos clientes.

Para isso, serão estabelecidas as seguintes metas:

- Analisar e documentar a estrutura da base de dados original;
- Identificar as principais entidades, atributos e relacionamentos presentes nos dados;
- Normalizar a base, reduzindo redundâncias e inconsistências;
- Desenvolver indicadores relacionados às vendas, faturamento, produtos, clientes e regiões;
- Analisar o comportamento dos clientes considerando aspectos como recência, frequência e valor das compras;

- Identificar padrões de consumo e possíveis segmentos de clientes com comportamentos semelhantes;
- Desenvolver relatórios e visualizações para apresentar os principais resultados das análises;
- Gerar insights que possam contribuir para a tomada de decisões e estratégias comerciais da organização;
- Documentar o desenvolvimento do projeto e integrar os materiais produzidos ao GitHub.

5. QUESTÃO DO NEGÓCIO

A partir das características da organização e dos dados disponíveis, o projeto buscará responder à seguinte questão:

Como a estruturação e análise dos dados históricos de vendas pode auxiliar uma empresa de varejo eletrônico a compreender o comportamento de seus clientes, identificar diferentes perfis de consumo e apoiar suas estratégias comerciais?

A questão de negócio será utilizada para direcionar as análises realizadas ao longo do projeto.

6. RESULTADOS ESPERADOS

Ao final do projeto, espera-se obter uma estrutura de banco de dados relacional organizada, normalizada e adequada para consultas e análises, permitindo centralizar e relacionar informações de clientes, produtos, faturas e itens comercializados.

A estrutura deverá permitir o relacionamento entre clientes, produtos, faturas e itens vendidos, possibilitando consultas sobre histórico de compras, produtos comercializados, valores faturados e distribuição das vendas por região.

Também se espera que a aplicação de técnicas de agrupamento permita identificar perfis de clientes com comportamentos semelhantes, fornecendo uma visão mais aprofundada da carteira de consumidores.

Os resultados serão apresentados por meio de consultas, indicadores, visualizações e análises interpretativas, buscando demonstrar como os dados podem ser utilizados para gerar insights e apoiar decisões estratégicas.

7. LINGUAGEM E BIBLIOTECAS

A linguagem de programação definida para o desenvolvimento do projeto será **Python**, devido à sua ampla utilização nas áreas de análise de dados, ciência de dados e aprendizado de máquina, além da facilidade de integração com diferentes bibliotecas voltadas para tratamento, análise e visualização de informações.

No projeto, Python é utilizado para realizar o carregamento, tratamento, organização e análise do conjunto de dados Online Retail. A biblioteca **Pandas** é empregada para manipulação dos dados por meio de DataFrames, permitindo operações como leitura do arquivo Excel, identificação de valores ausentes, criação de novas variáveis, agrupamentos e geração de tabelas para análise.

A biblioteca **NumPy** é utilizada como apoio para operações numéricas e transformações matemáticas. Para a construção das visualizações gráficas são utilizadas as bibliotecas **Matplotlib** e **Seaborn**, que permitem representar os resultados das análises de maneira visual e facilitar a identificação de padrões presentes nos dados.

O projeto também utiliza a biblioteca **Scikit-learn** para aplicação de técnicas de aprendizado de máquina não supervisionado. O **StandardScaler** é utilizado para padronizar as variáveis antes da aplicação do algoritmo de agrupamento, enquanto o **K-Means** é empregado para segmentar os clientes de acordo com características de comportamento de compra. Para avaliar a qualidade dos agrupamentos gerados, são utilizadas métricas como **Silhouette Score** e **Davies-Bouldin Score**.

Além disso, a biblioteca nativa **os** é utilizada para auxiliar na organização dos arquivos gerados pelo projeto, permitindo a criação automática de diretórios destinados ao armazenamento de gráficos e resultados.

A escolha de Python também está relacionada à análise **RFM (Recency, Frequency e Monetary)** realizada no projeto, na qual são avaliadas a recência das compras, a

frequência de compras e o valor monetário associado a cada cliente. Essas informações posteriormente são utilizadas no processo de segmentação com o algoritmo K-Means.

Dessa forma, Python foi escolhido por oferecer uma sintaxe acessível, grande quantidade de bibliotecas especializadas e recursos adequados para todas as principais etapas do projeto, desde a preparação e exploração dos dados até a geração de gráficos, análise do comportamento dos clientes e aplicação de técnicas de agrupamento.

8. BASES TEÓRICAS DOS MÉTODOS

O projeto tem como objetivo realizar a segmentação dos clientes a partir do histórico de compras. Para isso, serão utilizadas técnicas de análise de dados e aprendizado de máquina não supervisionado, já que os grupos de clientes não são definidos antes da aplicação do modelo. A ideia é utilizar os próprios dados para encontrar clientes que apresentam comportamentos de compra semelhantes.

8.1 Análise RFM

Para representar o comportamento de cada cliente, será utilizada a análise RFM, que considera três características: Recency (Recência), Frequency (Frequência) e Monetary (Valor Monetário).

A Recência mostra há quanto tempo o cliente realizou sua última compra. Quanto menor esse valor, mais recente foi a compra.

A Frequência representa a quantidade de compras realizadas pelo cliente durante o período analisado. Assim, um cliente com uma frequência maior realizou compras mais vezes.

Já o Valor Monetário corresponde ao total gasto pelo cliente no período analisado. Essa variável permite observar quais clientes movimentaram valores maiores nas compras.

A utilização dessas três informações permite transformar o histórico de compras em um perfil numérico para cada cliente. No projeto, cada cliente será representado por

seus valores de Recência, Frequência e Valor Monetário, que posteriormente serão utilizados na segmentação.

8.2 Transformação dos dados

Antes de aplicar o algoritmo de agrupamento, os dados precisam ser preparados. Uma das etapas realizadas no projeto é a transformação logarítmica utilizando `log1p`.

Essa transformação é importante porque algumas variáveis podem apresentar valores muito diferentes entre os clientes, principalmente o valor gasto. Por exemplo, enquanto alguns clientes podem ter realizado compras de valores menores, outros podem ter movimentado valores muito altos.

A transformação logarítmica reduz essa diferença e diminui a influência dos valores extremos. Isso deixa os dados mais adequados para a etapa de agrupamento.

8.3 Padronização

Depois da transformação, é utilizada a padronização por meio do StandardScaler, disponível na biblioteca Scikit-learn.

Essa etapa é necessária porque as três variáveis do RFM possuem escalas diferentes. Recência pode representar uma quantidade de dias, Frequência uma quantidade de compras e Monetary valores financeiros.

Com isso, as variáveis ficam em uma escala comparável. Essa etapa é especialmente importante para o K-Means, pois o algoritmo utiliza a distância entre os pontos para definir quais clientes são mais semelhantes.

8.4 Aprendizado não supervisionado e K-Means

O método escolhido para realizar a segmentação é o K-Means, que pertence ao aprendizado de máquina não supervisionado.

Nesse tipo de aprendizado, o modelo não recebe previamente a informação de qual grupo cada cliente deveria pertencer. Em vez disso, o algoritmo procura padrões nos próprios dados e organiza os clientes em grupos com características semelhantes.

No caso do projeto, o K-Means recebe os dados de RFM já transformados e padronizados e procura formar grupos de clientes com comportamentos próximos.

O funcionamento do K-Means começa com a definição de uma quantidade de grupos, representada por K. Para cada grupo existe um ponto central, chamado de centróide.

O algoritmo calcula a distância entre cada cliente e os centróides e associa o cliente ao centróide mais próximo. Depois disso, os centróides são recalculados de acordo com os clientes que foram colocados em cada grupo. Esse processo é repetido até que os grupos apresentem estabilidade.

De maneira geral, o K-Means procura minimizar a distância entre os clientes e os centróides de seus respectivos grupos. Isso significa que o algoritmo busca formar grupos em que os clientes sejam mais próximos entre si, considerando as características utilizadas.

8.5 Definição do número de clusters

Um ponto importante na utilização do K-Means é decidir quantos grupos serão utilizados. Não existe uma quantidade de clusters definida previamente para o problema, por isso são testadas diferentes possibilidades.

No projeto, são analisados diferentes valores de K para verificar como os resultados se comportam. Para auxiliar nessa decisão, são utilizadas métricas como Inertia, Silhouette Score e Davies-Bouldin Score.

8.6 Inertia e Método do Cotovelo

A Inertia representa a soma das distâncias quadráticas entre os clientes e os centróides dos grupos aos quais eles pertencem.

Quando a quantidade de clusters aumenta, a Inertia tende a diminuir, porque os grupos ficam menores e os clientes ficam mais próximos dos seus centróides.

Porém, aumentar o número de grupos indefinidamente não significa que a segmentação será melhor. Por isso, a Inertia é utilizada no Método do Cotovelo (Elbow Method).

Nesse método, são observados os valores de Inertia para diferentes quantidades de clusters. Procura-se um ponto em que a redução da Inertia deixa de ser tão significativa. Esse ponto é chamado de “cotovelo” e pode auxiliar na escolha da quantidade de grupos.

9. DEFINIÇÃO DA ACURÁCIA

A avaliação de desempenho dos métodos analíticos é uma etapa essencial para garantir a confiabilidade dos resultados obtidos. Em modelos de aprendizado de máquina supervisionado, especialmente em problemas de classificação, uma das métricas mais utilizadas é a acurácia.

A acurácia mede a proporção de previsões corretas realizadas por um modelo em relação ao total de previsões efetuadas. Seu cálculo é dado pela razão entre o número de acertos e o número total de instâncias avaliadas:

Acurácia = Número de previsões corretas / Total de previsões

Essa métrica fornece uma visão geral do desempenho do modelo e possui interpretação simples. Entretanto, deve ser utilizada com cautela em bases desbalanceadas, pois uma classe muito mais frequente pode produzir uma acurácia elevada sem representar, necessariamente, um bom desempenho para todas as classes.

Em problemas de classificação, a análise pode ser complementada por métricas derivadas da matriz de confusão, como precisão (Precision), que mede a proporção de previsões positivas corretas; recall (Sensibilidade), que avalia a capacidade de identificar corretamente os casos positivos; e F1-Score, que representa a média harmônica entre precisão e recall.

Caso sejam utilizados modelos de regressão, métricas como erro médio absoluto (MAE) e raiz do erro quadrático médio (RMSE) são mais adequadas, pois medem a diferença entre os valores previstos e os valores reais. Técnicas como validação cruzada também podem ser empregadas para obter estimativas mais robustas do desempenho em dados não utilizados no treinamento.

No contexto deste projeto, porém, o principal método de aprendizado de máquina aplicado é o K-Means, utilizado para segmentar clientes de um e-commerce com base nos indicadores RFM - Recency, Frequency e Monetary. Como o K-Means é um algoritmo de aprendizado não supervisionado, não existem classes verdadeiras previamente definidas para comparar diretamente com os grupos gerados. Dessa forma, a acurácia tradicional não é a medida principal de avaliação do modelo utilizado neste trabalho.

Para avaliar a qualidade dos agrupamentos, foram utilizadas métricas adequadas a problemas de clusterização. A Inertia mede a dispersão interna dos dados em relação aos centroides dos clusters e auxilia na aplicação do método do cotovelo. O Silhouette Score avalia o grau de coesão dos elementos dentro de um mesmo grupo e a separação em relação aos demais grupos. Já o Davies-Bouldin Score compara a dispersão interna dos clusters com a distância entre eles, sendo desejáveis, em geral, valores menores.

Foram testados valores de K entre 2 e 10. A análise conjunta da Inertia, do método do cotovelo, do Silhouette Score e do Davies-Bouldin Score apoiou a escolha de K = 2 para a segmentação final. Para esse agrupamento, o Silhouette Score foi de aproximadamente 0,433 e o Davies-Bouldin Score de aproximadamente 0,892.

Assim, embora a acurácia seja uma métrica relevante para modelos supervisionados, a avaliação adotada neste projeto está concentrada em medidas específicas de aprendizado não supervisionado. A utilização conjunta de Inertia, Silhouette Score e Davies-Bouldin Score permite avaliar de forma mais coerente a qualidade da segmentação e verificar se os grupos identificados apresentam características suficientemente distintas para apoiar análises sobre o comportamento dos clientes e estratégias comerciais do e-commerce.

10. ANÁLISE EXPLORATÓRIA

A análise exploratória teve como objetivo compreender a estrutura e a qualidade dos dados antes da aplicação dos métodos analíticos. Foram verificados o número de registros e atributos, tipos das variáveis, valores ausentes, registros duplicados, valores negativos ou inconsistentes e a distribuição das informações.

Também foram analisadas características comerciais da base, como quantidade de produtos e clientes, número de faturas, países presentes e evolução do faturamento ao longo do período. Essas análises permitem compreender o comportamento geral das transações e identificar possíveis problemas que precisam ser tratados antes da aplicação das técnicas de aprendizado de máquina.

A análise exploratória também serviu de base para a construção dos indicadores de comportamento dos clientes, considerando principalmente recência, frequência e valor monetário das compras, aspectos que fazem parte dos objetivos definidos para o projeto.

11. TRATAMENTO, PREPARAÇÃO E TREINAMENTO

Após a análise exploratória, foi realizada a preparação da base para garantir maior consistência na aplicação das técnicas de análise e agrupamento.

Inicialmente, foram identificadas as transações canceladas. No conjunto de dados, os registros cujo InvoiceNo começa com a letra C representam cancelamentos. Esses registros foram separados da base utilizada para a segmentação dos clientes, mas podem ser mantidos para análises específicas sobre cancelamentos e comportamento das transações.

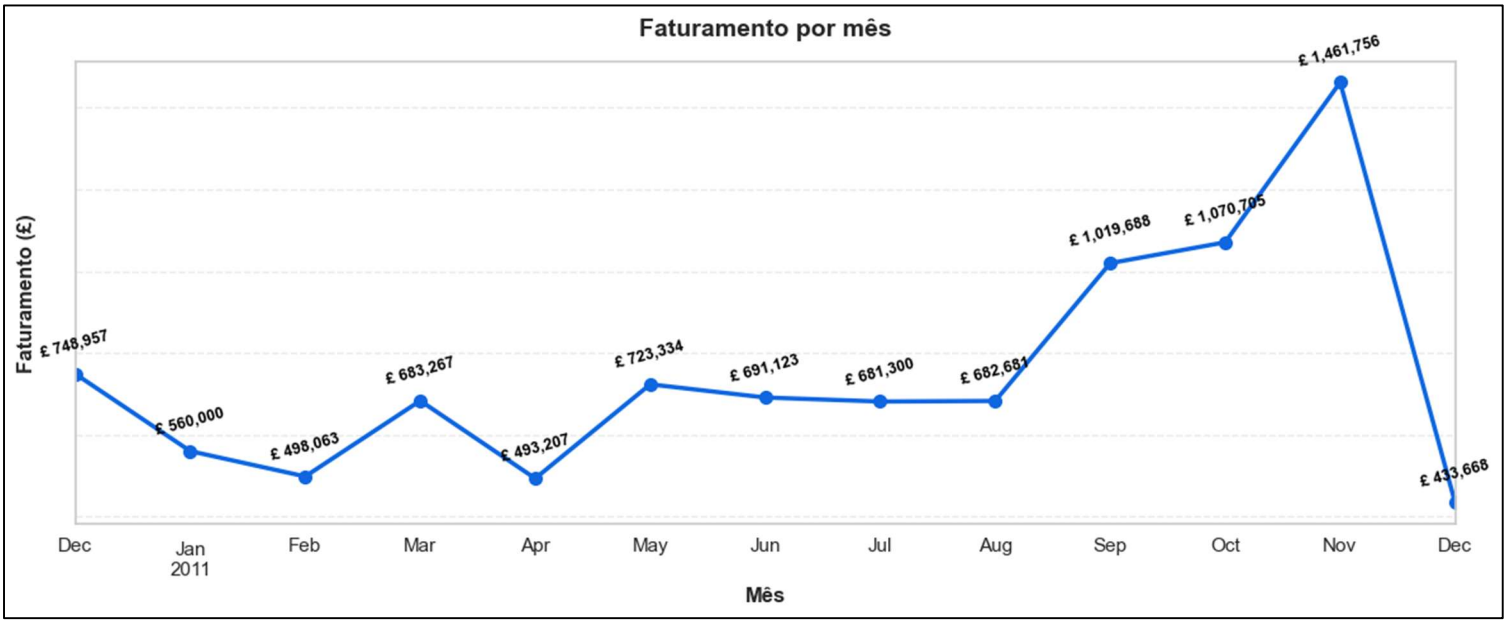
Também foram tratados registros com quantidades negativas, preços unitários inválidos e registros duplicados. O objetivo dessa etapa foi evitar que valores que não representam adequadamente uma compra concluída influenciassem os indicadores utilizados na segmentação.

Após o tratamento, foi criada a variável TotalPrice, calculada pela multiplicação entre quantidade e preço unitário:

TotalPrice = Quantity × UnitPrice

	Quantity	UnitPrice	TotalPrice
0	6	2.55	15.30
1	6	3.39	20.34
2	8	2.75	22.00
3	6	3.39	20.34
4	6	3.39	20.34
5	2	7.65	15.30

Essa variável representa o valor total de cada item da transação e permite realizar análises relacionadas ao faturamento.



O gráfico de faturamento mensal apresenta a evolução dos valores comercializados durante o período analisado. Essa visualização permite observar a variação do faturamento ao longo dos meses e identificar períodos de maior ou menor movimentação comercial.

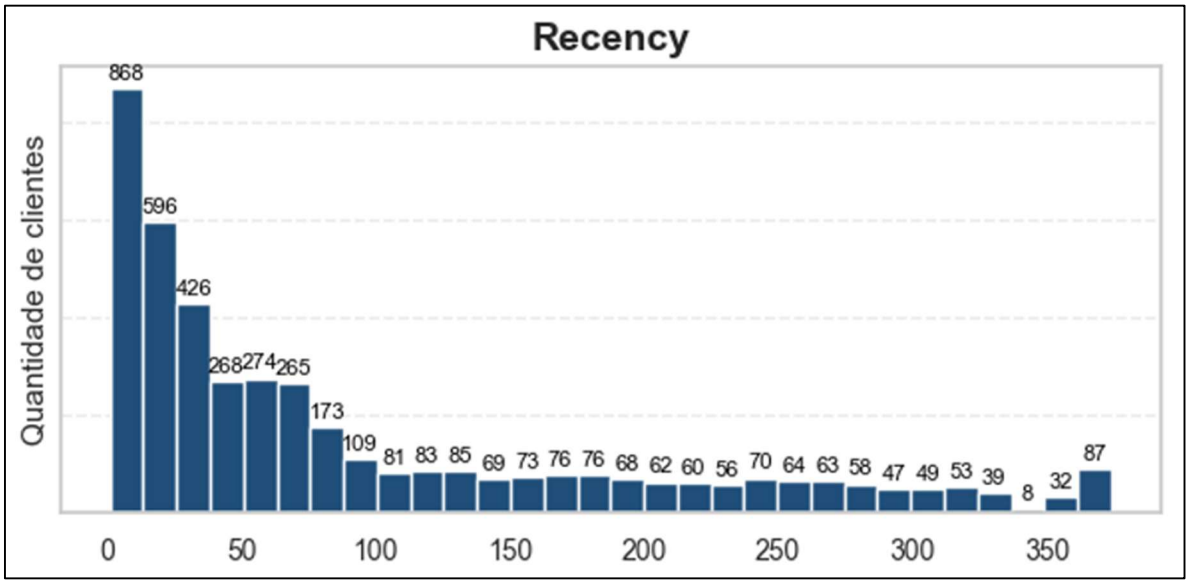
Para a segmentação dos clientes foi utilizada a metodologia RFM, considerando três indicadores:

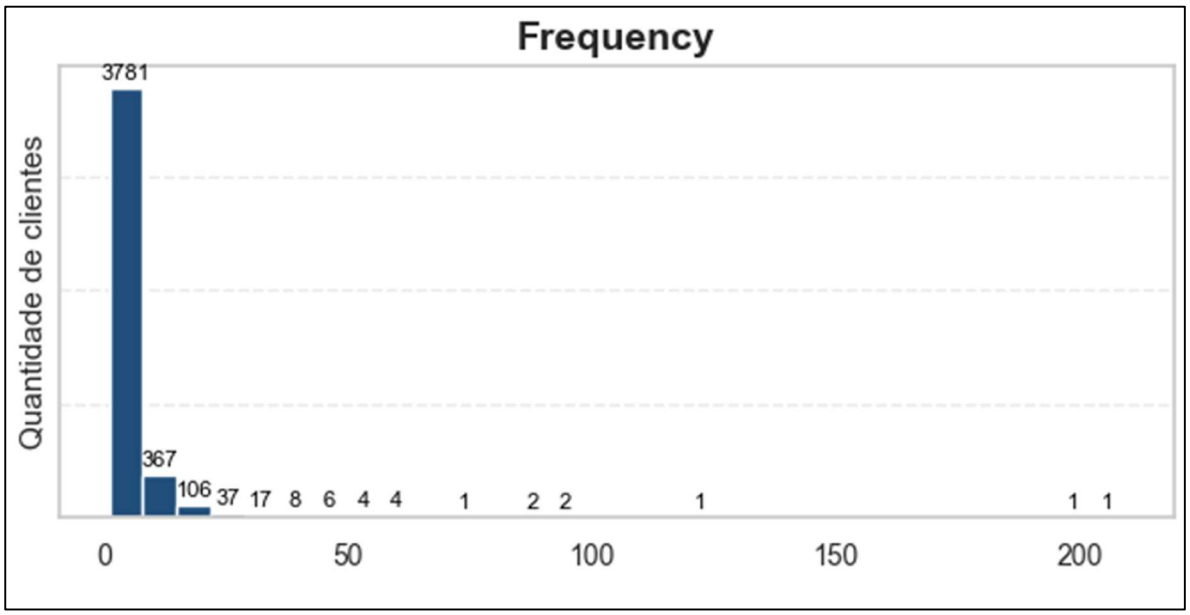
- Recency (Recência): quantidade de dias desde a última compra do cliente;
- Frequency (Frequência): quantidade de compras realizadas pelo cliente;
- Monetary (Valor Monetário): valor total gasto pelo cliente.

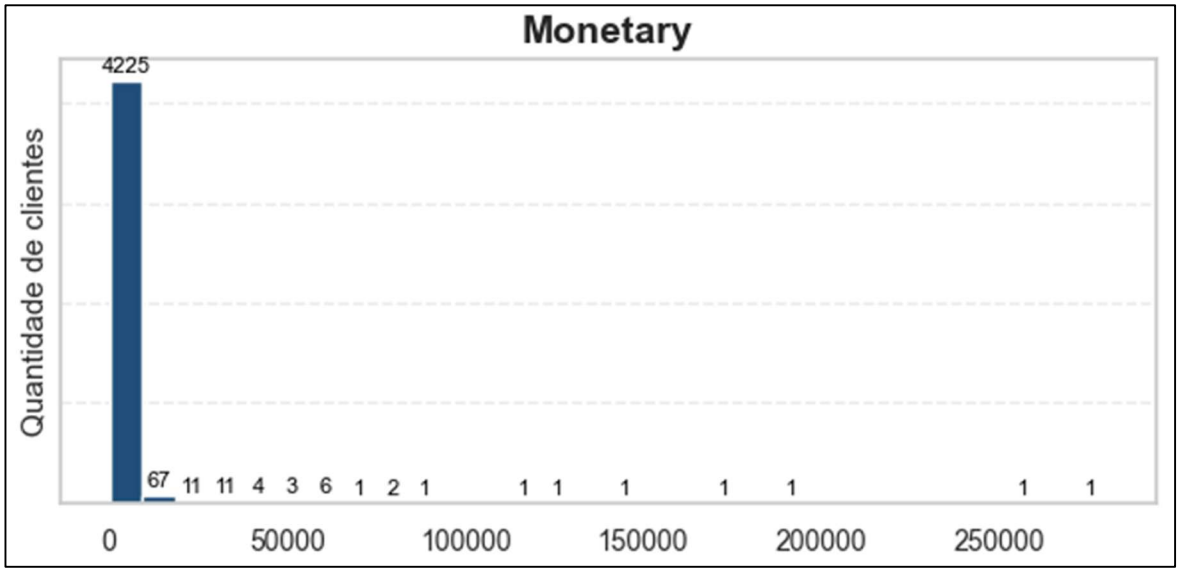
Esses indicadores foram calculados individualmente para cada CustomerID, permitindo representar o comportamento de compra de cada cliente.

CustomerID	Recency	Frequency	Monetary
12346.0	326	1	77183.60
12347.0	2	7	4310.00
12348.0	75	4	1797.24
12349.0	19	1	1757.55
12350.0	310	1	334.40

Os histogramas permitem visualizar como os clientes estão distribuídos em relação a cada indicador e identificar possíveis concentrações ou valores extremos.







Como os valores de RFM apresentam distribuições assimétricas e podem possuir valores extremos, foi aplicada a transformação logarítmica log1p. Posteriormente, os dados foram padronizados utilizando o StandardScaler. Essa etapa é importante porque o K-Means utiliza medidas de distância e, portanto, variáveis com escalas muito diferentes poderiam exercer influência desproporcional no agrupamento.

Log1p:

CustomerID	Recency	Frequency	Monetary
12346.0	5.789960	0.693147	11.253955
12347.0	1.098612	2.079442	8.368925
12348.0	4.330733	1.609438	7.494564
12349.0	2.995732	0.693147	7.472245
12350.0	5.739793	0.693147	5.815324

StandardScaler:

```
array([[ 1.46199281, -0.95521426,  3.7077163 ],
       [-2.03873442,  1.07442519,  1.41490344],
       [ 0.37310424,  0.38630445,  0.72002428],
       [-0.62308592, -0.95521426,  0.70228691],
       [ 1.42455753, -0.95521426, -0.61451388]])
```

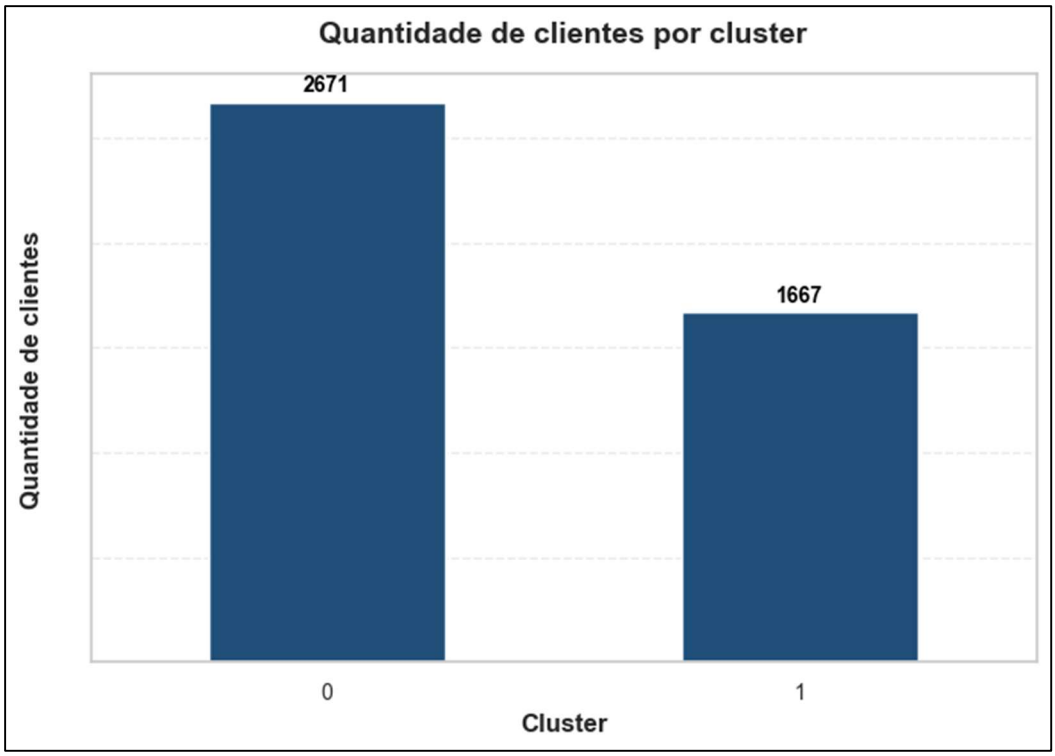
Após a preparação dos dados, foi aplicado o algoritmo K-Means, um método de aprendizado de máquina não supervisionado utilizado para agrupar clientes com características semelhantes. Foram testados valores de K entre 2 e 10, permitindo comparar diferentes quantidades de grupos.

A definição do número de clusters foi apoiada pelo método do cotovelo, pelo Silhouette Score e pelo Davies-Bouldin Score. A partir dessa avaliação, foi utilizado **K = 2** no agrupamento final, resultando em dois grupos de clientes. Os valores 0 e 1 atribuídos pelo algoritmo representam apenas identificadores dos clusters e não significam, por si só, que um grupo seja melhor ou pior que o outro, esse significado é interpretado a partir das características dos grupos obtidos.

	K	Inertia	Silhouette	Davies_Bouldin
0	2	6483.589425	0.432827	0.892499
1	3	4869.488629	0.336517	1.048336
2	4	3938.603205	0.337335	1.010579
3	5	3296.708708	0.316200	0.987779
4	6	2855.525596	0.312802	1.015594
5	7	2548.820245	0.309186	0.982334
6	8	2336.341054	0.303275	0.989165
7	9	2156.005673	0.281085	1.019266
8	10	2000.573165	0.278127	1.023669

Após o treinamento, cada cliente recebeu a identificação do cluster ao qual foi atribuído. Os grupos obtidos foram posteriormente utilizados para analisar as características dos clientes e interpretar seus diferentes padrões de comportamento de compra.

CustomerID	Recency	Frequency	Monetary	Cluster
12346.0	326	1	77183.60	1
12347.0	2	7	4310.00	1
12348.0	75	4	1797.24	1
12349.0	19	1	1757.55	0
12350.0	310	1	334.40	0



12. RESULTADOS E ARQUIVOS GERADOS

Após a definição do agrupamento, foram gerados arquivos CSV para registrar os resultados obtidos e permitir sua utilização em análises posteriores.

12.1 rfm_clientes.csv

Apresenta os indicadores Recency, Frequency e Monetary calculados para cada cliente. O arquivo permite consultar individualmente as características de comportamento utilizadas na segmentação.

1	CustomerID	Recency	Frequency	Monetary	Cluster
2	12346.0	326	1	77183.6	1
3	12347.0	2	7	4310.0	1
4	12348.0	75	4	1797.24	1
5	12349.0	19	1	1757.55	0

12.2 perfil_clusters.csv

Apresenta um resumo das características de cada cluster, incluindo quantidade de clientes, médias de Recência, Frequência e Valor Monetário, faturamento total e participação no faturamento. Esse arquivo permite interpretar as características dos grupos identificados pelo modelo.

1	Cluster	Clientes	Recencia_Media	Frequencia_Media	Valor_Medio	Faturamento_Total	Participacao_Faturamento_%
2	0	2671	134.12	1.67	495.43	1323290.32	14.89
3	1	1667	25.91	8.44	4537.44	7563918.57	85.11

12.3 avaliacao_clusters.csv

Registra os resultados obtidos para cada valor de K testado, incluindo Inertia, Silhouette Score e Davies-Bouldin Score. O arquivo permite documentar a comparação entre os diferentes agrupamentos avaliados.

1	K	Inertia	Silhouette	Davies_Bouldin
2	2	6483.589425039297	0.4328265515350662	0.8924990931024944
3	3	4869.488628540216	0.3365174636950013	1.0483361748315712
4	4	3938.6032045582506	0.33733468086891827	1.01057912537452
5	5	3296.7087076425437	0.3162001336222631	0.9877789358456204
6	6	2855.52559576711	0.31280161157605324	1.0155938179824024
7	7	2548.820244849563	0.30918598433785954	0.9823343832117389
8	8	2336.341053610392	0.30327504528060134	0.9891648541565694
9	9	2156.005672521344	0.281084500299107	1.019266115296476
10	10	2000.5731646214847	0.2781269930252871	1.0236685733119573

12. 4 clientes_com_clusters.csv

Relaciona cada cliente ao cluster atribuído pelo modelo. Esse arquivo permite utilizar a segmentação em análises posteriores, relacionando os grupos identificados aos produtos, países e demais informações presentes nas transações.

InvoiceNo,StockCode,Description,Quantity,InvoiceDate,UnitPrice,CustomerID,Country,TotalPrice,Month,Cluster
536365,85123A,WHITE HANGING HEART T-LIGHT HOLDER,6,2010-12-01 08:26:00,2.55,17850.0,United Kingdom,15.299999999999999,2010-12,1
536365,71053,WHITE METAL LANTERN,6,2010-12-01 08:26:00,3.39,17850.0,United Kingdom,20.34,2010-12,1
536365,84406B,CREAM CUPID HEARTS COAT HANGER,8,2010-12-01 08:26:00,2.75,17850.0,United Kingdom,22.0,2010-12,1
536365,84029G,KNITTED UNION FLAG HOT WATER BOTTLE,6,2010-12-01 08:26:00,3.39,17850.0,United Kingdom,20.34,2010-12,1
536365,84029E,RED WOOLLY HOTTIE WHITE HEART.,6,2010-12-01 08:26:00,3.39,17850.0,United Kingdom,20.34,2010-12,1

13. CRONOGRAMA

Etapas	Atividade	Ago.	Set.	Out.	Nov.
Etapa 1 - Kick-off	Definição do grupo de trabalho;	**24/08**			
	Definição da base da dados;	**25/08**			
	Objetivos e metas;	**26/08**			
	Cronograma.	**28/08**			
Etapa 2 - Preparação dos dados	Definição das bibliotecas;		**04/09**		
	Métodos analíticos;		**11/09**		
	Análise exploratória;		**18/09**		
	Tratamento da base de dados.		**22/09**		
Etapa 3 - Análise e resultados	Aplicação dos métodos;			**30/09**	
	Medidas de avaliação;			**02/10**	
	Relatório analítico;			**09/10**	
	Resultados preliminares;			**16/10**	
	Storytelling.			**20/10**	
Etapa 4 - Finalização	Relatório técnico do projeto;				**05/11**
	Apresentação do Storytelling, em PPT ou similar;				**11/11**

	Repositório no GitHub contendo os arquivos do projeto;				**16/11**
	Vídeo da apresentação no YouTube, utilizando a técnica de Storytelling.				**20/11**